Théorie des langages et Compilation : Analyse Lexicale

Didier Lime

École Centrale de Nantes – LS2N

Année 2017 - 2018

Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

Conclusion

Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

Conclusion

Analyse lexicale

- Le but de l'analyse lexicale est de transformer une suite de caractères en mots (lexèmes ou *tokens*).
- L'analyse syntaxique vient ensuite examiner l'agencement des mots
- L'analyseur syntaxique est strictement plus puissant que l'analyseur lexical
- ▶ La passe « analyse lexicale » est faite par commodité

Première idée

Exemple

```
void readIdentifier(char* token, char * s) {
    int i = 0;
    char c:
    while ((c = getc()) != EOF && c >= 'a' && c <= 'z') {</pre>
        s[i] = c;
        i++;
    if (!contains(keyword_table, s))
       strcpy(token, IDENTIFIER);
    else
       strcpy(token, KEYWORD);
void readInteger(char* token, char * id) { ... }
```

(Inspiré de l'exemple du cours de Compilation de J. Ferber, Montpellier)

Première idée

- ► Chaque fonction reconnaît assez bien les mots composés par la répétition *C** de caractères d'une même classe *C*
- Pour des constructions plus compliquées les fonctions deviennent lourdes
- Quelle fonction appeler?
- Nécessité d'une approche globale et donc générique

Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

Conclusion

Langages Formels

Lettres et mots :

- Soit un ensemble fini Σ. On l'appelle alphabet;
- Les éléments de Σ sont appelés lettres;
- Les **mots** sont des séquences de lettres $a_1 \dots a_N$;
- ▶ On note Σ^* l'ensemble des mots sur Σ
- ► On note *uv* le mot obtenu par **concaténation** de deux mots *u* et *v*;
- La concaténation est associative;
- ▶ On note son élément neutre ϵ , appelé mot vide;

Langages Formels

Lettres et mots :

- Soit un ensemble fini Σ. On l'appelle alphabet;
- Les éléments de Σ sont appelés lettres;
- Les **mots** sont des séquences de lettres $a_1 \dots a_N$;
- ▶ On note Σ^* l'ensemble des mots sur Σ
- ▶ On note *uv* le mot obtenu par **concaténation** de deux mots *u* et *v*;
- ► La concaténation est associative :
- ▶ On note son élément neutre ϵ , appelé mot vide;

Langages :

- ▶ Un langage sur Σ est un sous-ensemble de Σ^* ;
- ▶ Soient U et V deux langages sur Σ , $UV = \{uv | u \in U, v \in V\}$;
- ▶ $U^* = \{u_0 \dots u_n | n \ge 0, \forall i, u_i \in U\}$;

Langages Réguliers

- On veut reconnaître des langages;
- Le problème est a priori indécidable;
- On doit donc se contenter de langages particuliers;
- ➤ On veut en plus que l'analyse soit efficace : on choisit les langages réguliers.

Langages Réguliers

- On veut reconnaître des langages;
- Le problème est a priori indécidable;
- On doit donc se contenter de langages particuliers;
- ➤ On veut en plus que l'analyse soit efficace : on choisit les langages réguliers.

Définition (Langages réguliers)

Un langage est dit régulier s'il est reconnu par un automate fini.

Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

Conclusion

Automates Finis Déterministes (DFA)

Définition (DFA)

Un automate fini déterministe (DFA) est un quintuplet $(Q, \Sigma, \delta, q_0, F)$ où :

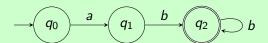
- Q est un ensemble fini d'états;
- Σ est un alphabet fini;
- δ : Q × Σ → Q est une fonction partielle appelée fonction de transition;
- ▶ $q_0 \in Q$ est l'état initial;
- ▶ $F \subseteq Q$ est l'ensemble des **états accepteurs** (ou terminaux).

Automates Finis Déterministes (DFA)

Définition (DFA)

Un automate fini déterministe (DFA) est un quintuplet $(Q, \Sigma, \delta, q_0, F)$ où :

- Q est un ensemble fini d'états;
- Σ est un alphabet fini;
- δ : Q × Σ → Q est une fonction partielle appelée fonction de transition;
- ▶ $q_0 \in Q$ est l'état initial;
- ▶ $F \subseteq Q$ est l'ensemble des **états accepteurs** (ou terminaux).

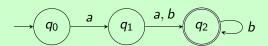


Automates Finis Déterministes (DFA)

Définition (DFA)

Un automate fini déterministe (DFA) est un quintuplet $(Q, \Sigma, \delta, q_0, F)$ où :

- Q est un ensemble fini d'états;
- Σ est un alphabet fini;
- δ : Q × Σ → Q est une fonction partielle appelée fonction de transition;
- q₀ ∈ Q est l'état initial;
- ▶ $F \subseteq Q$ est l'ensemble des **états accepteurs** (ou terminaux).



Soit un DFA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$

• δ peut être étendu sur $Q \times \Sigma^*$:

$$\forall w \in \Sigma^* \text{ t.q. } |w| \ge 2, \exists a \in \Sigma, w' \in \Sigma^* \text{ t.q. } w = aw'.$$

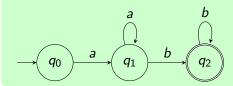
Alors,
$$\delta(q, w) = \delta(\delta(q, a), w')$$
;

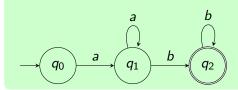
Soit un DFA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$

- ▶ δ peut être étendu sur $Q \times \Sigma^*$: $\forall w \in \Sigma^*$ t.q. $|w| \ge 2, \exists a \in \Sigma, w' \in \Sigma^*$ t.q. w = aw'. Alors, $\delta(q, w) = \delta(\delta(q, a), w')$;
- ▶ Un mot $w \in \Sigma^*$ est **accepté** (ou reconnu) par \mathcal{A} si $\delta(q_0, w) \in F$.

Soit un DFA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$

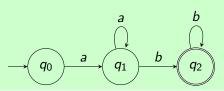
- ▶ δ peut être étendu sur $Q \times \Sigma^*$: $\forall w \in \Sigma^*$ t.q. $|w| \ge 2, \exists a \in \Sigma, w' \in \Sigma^*$ t.q. w = aw'. Alors, $\delta(q, w) = \delta(\delta(q, a), w')$;
- ▶ Un mot $w \in \Sigma^*$ est accepté (ou reconnu) par A si $\delta(q_0, w) \in F$.
- ▶ Le langage $\mathcal{L}(\mathcal{A})$ de \mathcal{A} est l'ensemble des mots acceptés par \mathcal{A} .



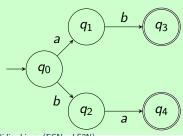


$$\mathcal{L}(\mathcal{A}) = \{a^mb^n|m,n\in\mathbb{N}\setminus\{0\}\}$$

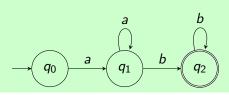
Exemple



$$\mathcal{L}(\mathcal{A}) = \{a^m b^n | m, n \in \mathbb{N} \setminus \{0\}\}$$

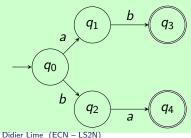


Exemple



$$\mathcal{L}(\mathcal{A}) = \{a^m b^n | m, n \in \mathbb{N} \setminus \{0\}\}$$

Exemple



$$\mathcal{L}(\mathcal{A}) = \{ab\} \cup \{ba\} = \{ab, ba\}$$

Année 2017 - 2018

Expressions Régulières

Pour décrire les langages, on utilise le formalisme des expressions régulières (aussi appelées rationnelles).

Définition (Expressions Régulières (RE))

Les expressions régulières sont définies inductivement par :

- ▶ Ø est une expression régulière
- $ightharpoonup \epsilon$ est une expression régulière
- ▶ $\forall a \in \Sigma$, a est un expression régulière
- ▶ Pour toutes expressions régulières r et s, rs et r | s sont des expressions régulières
- Pour toute expression régulière r, r^* est une expression régulière

Expressions Régulières

À chaque RE, on associe un langage :

Définition (Langage associé aux RE)

Le langage $\mathcal{L}(r)$ d'une RE r est défini par :

- $\triangleright \mathcal{L}(\emptyset) = \emptyset$;
- $\mathcal{L}(\epsilon) = \{\epsilon\};$
- ▶ $\forall a \in \Sigma, \mathcal{L}(a) = \{a\};$
- ▶ Pour toutes RE r et s, $\mathcal{L}(rs) = \mathcal{L}(r)\mathcal{L}(s)$ et $\mathcal{L}(r|s) = \mathcal{L}(r) \cup \mathcal{L}(s)$;
- ▶ Pour toute RE r, $\mathcal{L}(r^*) = \mathcal{L}(r)^*$.

Expressions Régulières

À chaque RE, on associe un langage :

Définition (Langage associé aux RE)

Le langage $\mathcal{L}(r)$ d'une RE r est défini par :

- $\triangleright \mathcal{L}(\emptyset) = \emptyset$;
- $\mathcal{L}(\epsilon) = \{\epsilon\};$
- ▶ $\forall a \in \Sigma, \mathcal{L}(a) = \{a\};$
- ▶ Pour toutes RE r et s, $\mathcal{L}(rs) = \mathcal{L}(r)\mathcal{L}(s)$ et $\mathcal{L}(r|s) = \mathcal{L}(r) \cup \mathcal{L}(s)$;
- ▶ Pour toute RE r, $\mathcal{L}(r^*) = \mathcal{L}(r)^*$.

L'union, la concaténation et l'étoile sont les opérations dites régulières sur les langages.

Expressions Régulières et Langages Réguliers

Théorème (Théorème de Kleene 1)

Pour toute expression régulière r, son langage $\mathcal{L}(r)$ est régulier.

Expressions Régulières et Langages Réguliers

Théorème (Théorème de Kleene 1)

Pour toute expression régulière r, son langage $\mathcal{L}(r)$ est régulier.

Théorème (Théorème de Kleene 2)

Pour tout langage régulier \mathcal{L} , il existe une expression régulière r telle que $\mathcal{L}(r)=\mathcal{L}$.

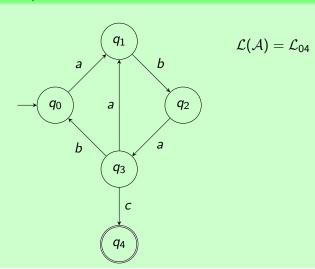
Expressions Régulières Étendues

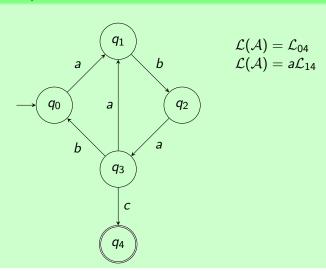
À partir des expressions précédentes, on peut définir les **raccourcis** suivants :

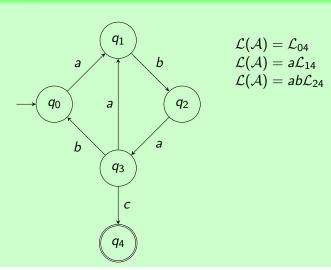
- ightharpoonup [abc] = a|b|c;
- ▶ Si Σ est ordonné, $[a_1 a_2] = \{b \in \Sigma | a_1 \le b \le a_2\}$;
- $ightharpoonup r? = r|\epsilon;$
- $r^+ = rr^*$:
- $[\hat{a}bc] = \Sigma \setminus \{a, b, c\};$
- $[\hat{a}_1 a_2] = \Sigma \setminus [a_1 a_2];$
- $\cdot = \Sigma$ et $* = \Sigma^*$.

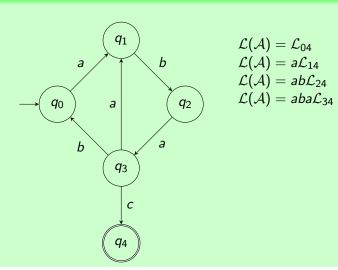
Soit un DFA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$.

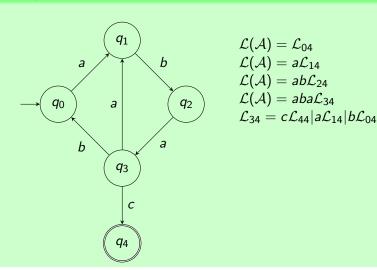
- ▶ On note \mathcal{L}_{ij} le langage de \mathcal{A} obtenu entre l'état q_i et l'état q_j ;
- ▶ Si $F = \{q_N, \dots, q_{N+k}\}$ alors $\mathcal{L}(\mathcal{A}) = \mathcal{L}_{0N}| \cdots | \mathcal{L}_{0N+k}$;
- ▶ Si q_{i+1}, \ldots, q_{i+k} sont les sucesseurs de q_i alors $\mathcal{L}_{ij} = \mathcal{L}_{ii+1}\mathcal{L}_{i+1j}|\cdots|\mathcal{L}_{ii+k}\mathcal{L}_{i+kj}$;
- S'il existe a_1, \ldots, a_k tels que $\delta(q_i, a_1) = \cdots = \delta(q_i, a_k) = q_j$ alors $\mathcal{L}_{ij} = a_1 | \cdots | a_k$;
- ▶ Si $\mathcal{L}_{ij} = r\mathcal{L}_{ij}|s$ alors $\mathcal{L}_{ij} = r^*s$;
- ▶ Si q_i n'a pas de boucle $(a \in \Sigma \text{ t.q. } \delta(q_i, a) = q_i)$ alors $\mathcal{L}_{ii} = \epsilon$.

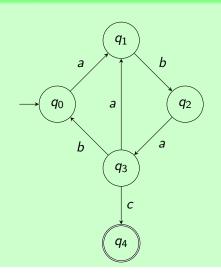




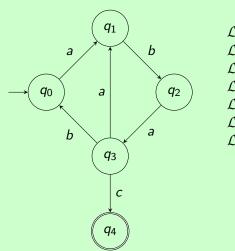






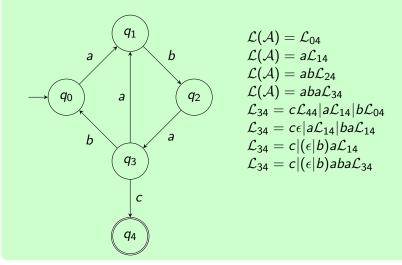


$$\mathcal{L}(\mathcal{A}) = \mathcal{L}_{04}$$
 $\mathcal{L}(\mathcal{A}) = a\mathcal{L}_{14}$
 $\mathcal{L}(\mathcal{A}) = ab\mathcal{L}_{24}$
 $\mathcal{L}(\mathcal{A}) = aba\mathcal{L}_{34}$
 $\mathcal{L}_{34} = c\mathcal{L}_{44}|a\mathcal{L}_{14}|b\mathcal{L}_{04}$
 $\mathcal{L}_{34} = c\epsilon|a\mathcal{L}_{14}|ba\mathcal{L}_{14}$

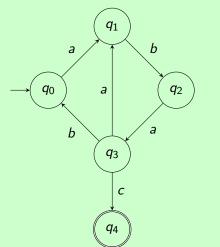


$$\mathcal{L}(\mathcal{A}) = \mathcal{L}_{04}$$
 $\mathcal{L}(\mathcal{A}) = a\mathcal{L}_{14}$
 $\mathcal{L}(\mathcal{A}) = ab\mathcal{L}_{24}$
 $\mathcal{L}(\mathcal{A}) = aba\mathcal{L}_{34}$
 $\mathcal{L}_{34} = c\mathcal{L}_{44}|a\mathcal{L}_{14}|b\mathcal{L}_{04}$
 $\mathcal{L}_{34} = c\epsilon|a\mathcal{L}_{14}|ba\mathcal{L}_{14}$
 $\mathcal{L}_{34} = c|(\epsilon|b)a\mathcal{L}_{14}$

Calcul du Langage d'un DFA

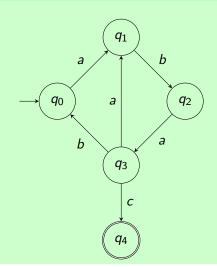


Calcul du Langage d'un DFA



$$\mathcal{L}(\mathcal{A}) = \mathcal{L}_{04}$$
 $\mathcal{L}(\mathcal{A}) = a\mathcal{L}_{14}$
 $\mathcal{L}(\mathcal{A}) = ab\mathcal{L}_{24}$
 $\mathcal{L}(\mathcal{A}) = aba\mathcal{L}_{34}$
 $\mathcal{L}_{34} = c\mathcal{L}_{44}|a\mathcal{L}_{14}|b\mathcal{L}_{04}$
 $\mathcal{L}_{34} = c\epsilon|a\mathcal{L}_{14}|ba\mathcal{L}_{14}$
 $\mathcal{L}_{34} = c|(\epsilon|b)a\mathcal{L}_{14}$
 $\mathcal{L}_{34} = c|(\epsilon|b)aba\mathcal{L}_{34}$
 $\mathcal{L}_{34} = ((\epsilon|b)aba\mathcal{L}_{34})^*c$

Calcul du Langage d'un DFA

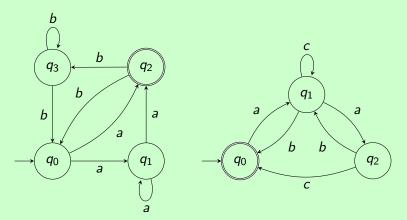


$$\mathcal{L}(\mathcal{A}) = \mathcal{L}_{04}$$
 $\mathcal{L}(\mathcal{A}) = a\mathcal{L}_{14}$
 $\mathcal{L}(\mathcal{A}) = ab\mathcal{L}_{24}$
 $\mathcal{L}(\mathcal{A}) = aba\mathcal{L}_{34}$
 $\mathcal{L}_{34} = c\mathcal{L}_{44}|a\mathcal{L}_{14}|b\mathcal{L}_{04}$
 $\mathcal{L}_{34} = c\epsilon|a\mathcal{L}_{14}|ba\mathcal{L}_{14}$
 $\mathcal{L}_{34} = c|(\epsilon|b)a\mathcal{L}_{14}$
 $\mathcal{L}_{34} = c|(\epsilon|b)aba\mathcal{L}_{34}$
 $\mathcal{L}_{34} = ((\epsilon|b)aba\mathcal{L}_{34})$
 $\mathcal{L}_{34} = ((\epsilon|b)aba\mathcal{L}_{34})$
 $\mathcal{L}_{34} = ((\epsilon|b)aba\mathcal{L}_{34})$
 $\mathcal{L}_{34} = ((\epsilon|b)aba\mathcal{L}_{34})$

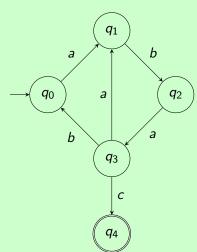
Calcul du Langage : Exercice

Exercice

Calculez des expressions rationnelles représentant les langages des automates (non déterministe pour celui de gauche) suivants :



Exemple

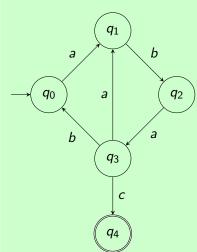


Didier Lime (ECN - LS2N)

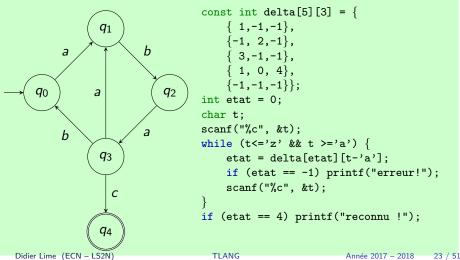
```
int etat = 0; char t;
                               scanf("%c", &t);
                               while (t<='z' && t >='a') {
               q_1
                                   switch (etat) {
                                        case 3:
                       b
        а
                                            switch (t) {
                                                 case 'a': etat=1; break;
   q_0
                          q_2
                                                 case 'b': etat=0; break;
                                                 case 'c': etat=4; break;
                                                 default: printf("erreur");
                       a
        b
                                             } break;
               q3
                                        case 0:
                                            switch (t) { ... } break;
                 C
                                   scanf("%c", &t);
               q4
                               if (etat == 4) printf("reconnu !");
Didier Lime (ECN - LS2N)
                                   TLANG
                                                           Année 2017 - 2018
                                                                          21 / 51
```

```
int etat = 0; char t;
                          scanf("%c", &t);
                          while (t<='z' && t >='a') {
           q_1
                               switch (t) {
                                   case 'a':
                  b
    а
                                        switch (etat) {
                                            case '0': etat=1; break;
90
                      q_2
                                            case '2': etat=3; break;
                                            case '3': etat=1; break;
                                            default: printf("erreur");
                  a
    b
                                        } break;
           q3
                                   case 'c':
                                        switch (t) { ... } break;
             C
                               scanf("%c", &t);
           q4
                           if (etat == 4) printf("reconnu !");
                              TLANG
                                                      Année 2017 - 2018
                                                                     22 / 51
```

Exemple



Didier Lime (ECN - LS2N)



Complétion d'un DFA

Définition (Complétude)

Un DFA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$ est dit **complet** si δ est définie pour tout $q \in Q$ et tout $a \in \Sigma$ (δ est une fonction totale).

Complétion d'un DFA

Définition (Complétude)

Un DFA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$ est dit **complet** si δ est définie pour tout $q \in Q$ et tout $a \in \Sigma$ (δ est une fonction totale).

- ▶ Pour rendre un automate complet, une méthode est de rajouter un état \ll erreur \gg q_{err} qui prend en compte les comportements imprévus;
- ▶ Si, pour $q \in Q$ et $a \in \Sigma$, $\delta(q, a)$ n'est pas défini alors on définit $\delta(q, a) = q_{err}$;
- C'est fait implicitement dans les implémentations précédentes.

Premier Bilan

- On sait qu'un langage régulier peut-être reconnu par un DFA;
- On sait implémenter un DFA;
- ▶ On sait exprimer un langage régulier par une expression régulière ;
- Étant donné un DFA, on sait calculer son langage

Premier Bilan

- On sait qu'un langage régulier peut-être reconnu par un DFA;
- On sait implémenter un DFA;
- On sait exprimer un langage régulier par une expression régulière;
- Étant donné un DFA, on sait calculer son langage

Reste:

- Comment savoir si un langage donné est régulier?
- ► Comment construire l'automate reconnaissant une RE particulière?

Prouver qu'un langage est régulier

Pour prouver qu'un langage $\mathcal L$ est régulier :

ightharpoonup Exprimer ${\cal L}$ comme le résultat d'opérations régulières sur des langages réguliers

Prouver qu'un langage est régulier

Pour prouver qu'un langage $\mathcal L$ est régulier :

- ightharpoonup Exprimer $\mathcal L$ comme le résultat d'opérations régulières sur des langages réguliers
- \triangleright Construire l'automate qui reconnaît \mathcal{L} (preuve constructive)

Prouver qu'un langage est régulier

Pour prouver qu'un langage $\mathcal L$ est régulier :

- ightharpoonup Exprimer $\mathcal L$ comme le résultat d'opérations régulières sur des langages réguliers
- ▶ Construire l'automate qui reconnaît L (preuve constructive)

Exercice

- ▶ Montrer que $\mathcal{L} = \{a^m b^n | m, n \in \mathbb{N}\}$ est régulier;
- Montrer que tout langage fini est régulier;
- Montrer que si ∠ est un langage régulier alors son inverse (l'ensemble de ses éléments inversés) est un langage régulier (p.ex. l'inverse de abc est cba);
- ▶ Idem pour son complémentaire.

Prouver qu'un langage n'est pas régulier

Lemme (Lemme de l'étoile (Pumping Lemma))

Pour tout langage régulier \mathcal{L} , il existe un entier n tel que pour tout mot w de longueur |w| supérieure à n, il existe des mots x, u et y de Σ^* tels que $u \neq \epsilon$, $|xu| \leq n$, w = xuy et $\forall k \geq 0, xu^k y \in \mathcal{L}$.

Exercice

Prouver que $\{a^nb^n, n \in \mathbb{N}\}$ n'est pas régulier

Prouver qu'un langage n'est pas régulier

Lemme (Lemme de l'étoile (Pumping Lemma))

Pour tout langage régulier \mathcal{L} , il existe un entier n tel que pour tout mot w de longueur |w| supérieure à n, il existe des mots x, u et y de Σ^* tels que $u \neq \epsilon$, $|xu| \leq n$, w = xuy et $\forall k \geq 0, xu^k y \in \mathcal{L}$.

Exercice

Prouver que $\{a^nb^n, n\in\mathbb{N}\}$ n'est pas régulier

Exercice

- 1. Prouver avec le lemme de l'étoile que $\{a^mb^n, m > n\}$ n'est pas régulier;
- 2. Prouver avec le lemme de l'étoile que $\{a^mb^n, m \neq n\}$ n'est pas régulier;
- 3. Prouver que si L_1 et L_2 sont réguliers alors $L_1 \cap L_2$ aussi ;
- 4. En déduire une autre preuve que $\{a^mb^n, m \neq n\}$ n'est pas régulier.

Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

Conclusion

Traduire une RE en un DFA

Théorème (Theorème de Kleene (rappel))

Les expressions régulières décrivent exactement les langages réguliers.

Traduire une RE en un DFA

Théorème (Theorème de Kleene (rappel))

Les expressions régulières décrivent exactement les langages réguliers.

Définition (Langages réguliers (rappel))

Un langage est dit régulier s'il est reconnu par un automate fini.

Traduire une RE en un DFA

Théorème (Theorème de Kleene (rappel))

Les expressions régulières décrivent exactement les langages réguliers.

Définition (Langages réguliers (rappel))

Un langage est dit régulier s'il est reconnu par un automate fini.

Traduire une RE en DFA n'est pas pratique : on va passer par les automates finis non déterministes.

Définition (NFA)

Un automate fini non déterministe (NFA) est un quintuplet $(Q, \Sigma, \delta, Q_0, F)$ où :

- Q est un ensemble fini d'états;
- Σ est un alphabet fini;
- ▶ $\delta: Q \times \Sigma \cup \{\epsilon\} \to \mathbf{2}^{\mathbf{Q}}$ est une fonction partielle appelée **fonction de transition**;
- ▶ Q₀ ⊆ Q est l'ensemble des états initiaux;
- ▶ $F \subseteq Q$ est l'ensemble des **états accepteurs** (ou terminaux).

Définition (NFA)

Un automate fini non déterministe (NFA) est un quintuplet $(Q, \Sigma, \delta, Q_0, F)$ où :

- Q est un ensemble fini d'états;
- Σ est un alphabet fini;
- ▶ $\delta: Q \times \Sigma \cup \{\epsilon\} \to \mathbf{2}^{\mathbf{Q}}$ est une fonction partielle appelée **fonction de transition**;
- ▶ Q₀ ⊆ Q est l'ensemble des états initiaux;
- ▶ $F \subseteq Q$ est l'ensemble des **états accepteurs** (ou terminaux).

Différences avec les DFA:

- On peut avoir plusieurs états initiaux et plusieurs transitions avec la même étiquette sortant d'un même état;
- Les transitions ϵ ne changent pas le mot qui est reconnu

La relation de transition d'un NFA est :

$$\delta: Q \times \Sigma \cup \{\epsilon\} \to \mathbf{2^Q}$$

La relation de transition d'un NFA est :

$$\delta: Q \times \Sigma \cup \{\epsilon\} \rightarrow \mathbf{2^Q}$$

▶ Et on a un ensemble d'états initiaux :

$$Q_0 \subseteq Q$$

La relation de transition d'un NFA est :

$$\delta: Q \times \Sigma \cup \{\epsilon\} \rightarrow \mathbf{2^Q}$$

▶ Et on a un ensemble d'états initiaux :

$$Q_0 \subseteq Q$$

► En exécutant l'automate sur un mot w on obtient donc un ensemble d'états :

$$\delta(Q_0, w) \in 2^Q$$

La relation de transition d'un NFA est :

$$\delta: Q \times \Sigma \cup \{\epsilon\} \rightarrow \mathbf{2^Q}$$

▶ Et on a un ensemble d'états initiaux :

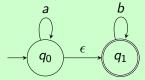
$$Q_0 \subseteq Q$$

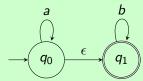
► En exécutant l'automate sur un mot w on obtient donc un ensemble d'états :

$$\delta(Q_0, w) \in 2^Q$$

Le mot est accepté si au moins l'un de ces états est final :

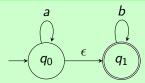
$$\delta(Q_0, w) \cap F \neq \emptyset$$



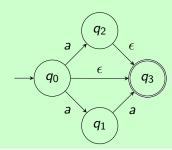


$$\mathcal{L}(\mathcal{A}) = a^*b^*$$

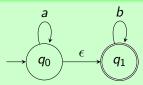
Exemple



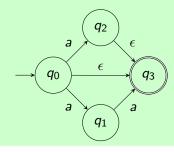
$$\mathcal{L}(\mathcal{A}) = a^*b^*$$



Exemple



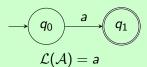
$$\mathcal{L}(\mathcal{A}) = a^*b^*$$



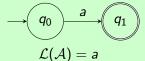
$$\mathcal{L}(\mathcal{A}) = \epsilon |a|$$
aa

Les **atomes** des RE se codent aisément avec les DFA et donc les NFA :

Les **atomes** des RE se codent aisément avec les DFA et donc les NFA :



Les **atomes** des RE se codent aisément avec les DFA et donc les NFA :



$$\rightarrow q_0$$

$$\mathcal{L}(\mathcal{A}) = \epsilon$$

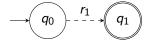
Les atomes des RE se codent aisément avec les DFA et donc les NFA :

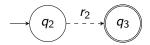
Exemple



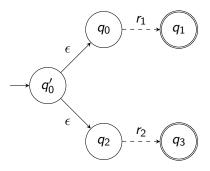
► Restent à coder : les opérations régulières

Union : $r_1 | r_2$

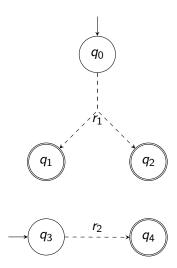




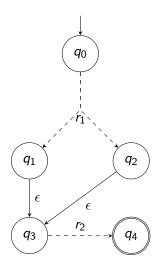
Union : $r_1 | r_2$



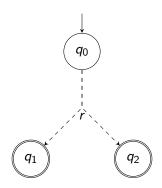
Concaténation : r_1r_2



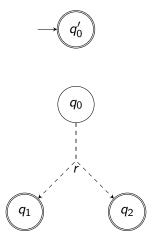
Concaténation : r_1r_2



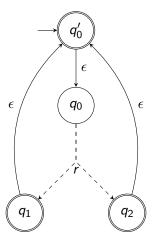
Fermeture (Étoile) de Kleene : r^*



Fermeture (Étoile) de Kleene : r^*



Fermeture (Étoile) de Kleene : r^*



Implémentation d'un NFA

```
list<int> T[5][3], E, nE;
                          list<int>::iterator i; char t;
                          E.push_back(0);
                          T[0][0].push_back(1); // q0 -a-> q1
                          T[0][0].push_back(2); // q0 -a-> q2
                          T[1][1].push_back(3); // q1 -b-> q3
           a
                          T[1][1].push_back(4); // q1 -b-> q4
  а
                          T[3][2].push_back(1); // q3 -\epsilon > q1
                          cin >> t:
               q_2
   q_1
                          while (t<='z' && t >='a') {
           b
b
        \epsilon
               q_4
                              E = nE; nE.clear();
   q3
                              cin >> t;
```

```
for (i=E.begin(); i != E.end(); i++) {
      nE.append(T[*i][t-'a']); // mais append
      epsilon-fermeture(nE); // n'existe pas
if (find(E.begin(), E.end(), 4) != E.end())
   cout << "reconnu" << endl;
```

Équivalence NFA - DFA

Théorème

Pour tout automate fini non déterministe A, il existe un automate fini déterministe $\Delta(A)$ qui reconnaît le même langage que A.

Équivalence NFA - DFA

Théorème

Pour tout automate fini non déterministe A, il existe un automate fini déterministe $\Delta(A)$ qui reconnaît le même langage que A.

Calculer $\Delta(A)$ est appelé « Déterminisation de A ».

Le principe est le même que celui utilisé pour l'implémentation précédente.

Soit
$$\mathcal{A} = (Q, \Sigma, \delta, Q_0, F)$$
. On définit $\Delta(\mathcal{A}) = (Q', \Sigma, \delta', q'_0, F')$

▶ $Q' = 2^Q$;

Le principe est le même que celui utilisé pour l'implémentation précédente. Soit $\mathcal{A} = (Q, \Sigma, \delta, Q_0, F)$. On définit $\Delta(\mathcal{A}) = (Q', \Sigma, \delta', q'_0, F')$

$$P Q' = 2^Q :$$

•
$$q_0' = Q_0$$
;

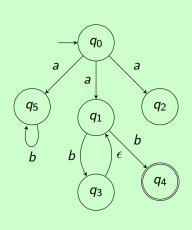
Le principe est le même que celui utilisé pour l'implémentation précédente.

Soit
$$\mathcal{A} = (Q, \Sigma, \delta, Q_0, F)$$
. On définit $\Delta(\mathcal{A}) = (Q', \Sigma, \delta', q'_0, F')$

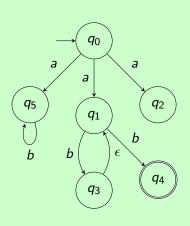
- ▶ $Q' = 2^Q$;
- $q_0' = Q_0$;
- ► $F' = \{ S \in 2^Q \mid F \cap S \neq \emptyset \} ;$

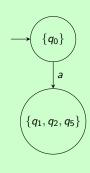
Le principe est le même que celui utilisé pour l'implémentation précédente. Soit $\mathcal{A} = (Q, \Sigma, \delta, Q_0, F)$. On définit $\Delta(\mathcal{A}) = (Q', \Sigma, \delta', g'_0, F')$

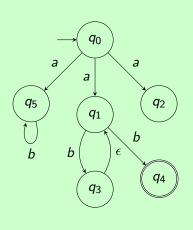
- $Q' = 2^Q$:
- $ightharpoonup q'_0 = Q_0$;
- ► $F' = \{ S \in 2^Q \mid F \cap S \neq \emptyset \} ;$
- ▶ $\forall q' \in Q', \forall a \in \Sigma, \delta'(q') = \epsilon \mathcal{F}(\bigcup_{q \in q'} \delta(q, a))$ où $\epsilon \mathcal{F}$ est le point fixe de la fonction $S \mapsto S \cup \{q | \exists q', q \in \delta(q', \epsilon)\}.$

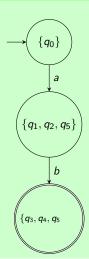


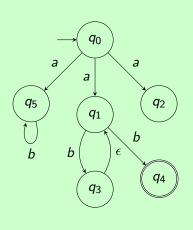


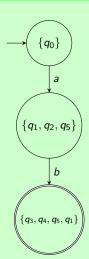


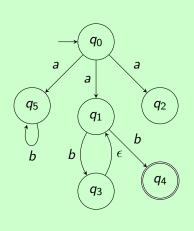


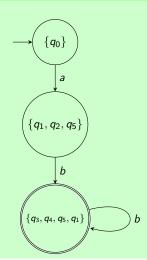








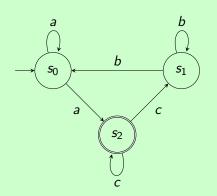


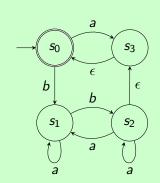


Déterminisation d'un NFA : Exercice

Exercice

Déterminisez les automates suivants :





Exercices

Exercice

Construisez un automate fini déterministe et complet qui reconnaît le langage $(a\Sigma^*b\Sigma^*a)^*$ pour $\Sigma = \{a, b\}$.

Exercices

Exercice

Construisez un automate fini déterministe et complet qui reconnaît le langage $(a\Sigma^*b\Sigma^*a)^*$ pour $\Sigma = \{a, b\}$.

Exercice

- 1. Construisez un NFA sur $\Sigma = \{a\}$ qui reconnaît le langage $\{(aaa)^m(aaaa)^n \mid m, n \geq 0\}$;
- 2. Construisez un DFA qui reconnaît son complémentaire;
- 3. Déduisez-en l'ensemble des nombres qui ne s'écrivent pas 3m + 4n avec m, n entiers naturels.

- La déterminisation fournit des automates potentiellement très gros;
- On définit une relation d'équivalence entre les états de l'automate;

- La déterminisation fournit des automates potentiellement très gros;
- On définit une relation d'équivalence entre les états de l'automate;

Définition (relation ≡)

On dit que deux états q et q' de $\mathcal{A}=(Q,\Sigma,\delta,q_0,F)$ sont équivalents si $\forall w\in\Sigma^*,\delta(q,w)\in F\Leftrightarrow\delta(q',w)\in F.$ On note alors $q\equiv q'.$

- ▶ La déterminisation fournit des automates potentiellement très gros;
- On définit une relation d'équivalence entre les états de l'automate;

Définition (relation ≡)

On dit que deux états q et q' de $\mathcal{A}=(Q,\Sigma,\delta,q_0,F)$ sont équivalents si $\forall w\in\Sigma^*,\delta(q,w)\in F\Leftrightarrow\delta(q',w)\in F.$ On note alors $q\equiv q'.$

Les états d'une même classe d'équivalence pourront être confondus.

- ▶ La déterminisation fournit des automates potentiellement très gros;
- On définit une relation d'équivalence entre les états de l'automate;

Définition (relation ≡)

On dit que deux états q et q' de $\mathcal{A}=(Q,\Sigma,\delta,q_0,F)$ sont équivalents si $\forall w\in\Sigma^*,\delta(q,w)\in F\Leftrightarrow\delta(q',w)\in F.$ On note alors $q\equiv q'.$

- Les états d'une même classe d'équivalence pourront être confondus.
- ▶ Pour construire les classes d'équivalence de \equiv , on définit \equiv_n :

Définition (relation \equiv_n)

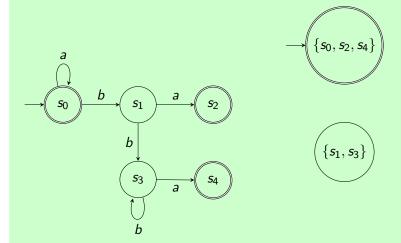
On dit que deux états q et q' de $\mathcal{A}=(Q,\Sigma,\delta,q_0,F)$ sont n-équivalents si $\forall w\in\Sigma^*$ t.q. $|w|\leq n$, $\delta(q,w)\in F\Leftrightarrow \delta(q',w)\in F$. On note alors $q\equiv_n q'$.

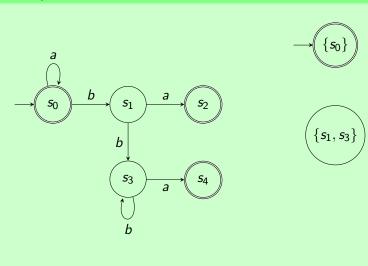
▶ De façon assez immédiate, la partition de Q induite par \equiv_0 est $\{F, Q \setminus F\}$;

- De façon assez immédiate, la partition de Q induite par ≡₀ est {F, Q \ F};
 Supposons qu'on a une partition P pour ≡ Soit P P' ∈ P Alors
- ▶ Supposons qu'on a une partition \mathcal{P}_n pour \equiv_n . Soit $P, P' \in \mathcal{P}_n$. Alors $\forall a \in \Sigma, \{q \in P | \delta(q, a) \in P'\}$ définit un élément de \mathcal{P}_{n+1} ;

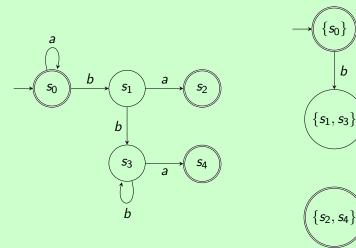
- ▶ De façon assez immédiate, la partition de Q induite par \equiv_0 est $\{F,Q\setminus F\}$;
- ▶ Supposons qu'on a une partition \mathcal{P}_n pour \equiv_n . Soit $P, P' \in \mathcal{P}_n$. Alors $\forall a \in \Sigma, \{q \in P | \delta(q, a) \in P'\}$ définit un élément de \mathcal{P}_{n+1} ;
- Le nombre d'éléments de \mathcal{P}_{n+1} est supérieur ou égal à celui de \mathcal{P}_n ;

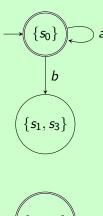
- ▶ De façon assez immédiate, la partition de Q induite par \equiv_0 est $\{F,Q\setminus F\}$;
- ▶ Supposons qu'on a une partition \mathcal{P}_n pour \equiv_n . Soit $P, P' \in \mathcal{P}_n$. Alors $\forall a \in \Sigma, \{q \in P | \delta(q, a) \in P'\}$ définit un élément de \mathcal{P}_{n+1} ;
- Le nombre d'éléments de \mathcal{P}_{n+1} est supérieur ou égal à celui de \mathcal{P}_n ;
- ▶ Le nombre de façons de partitionner Q est fini, donc $\exists k$ t.q. $\mathcal{P}_{k+1} = \mathcal{P}_k$. Alors $\equiv_k = \equiv$.

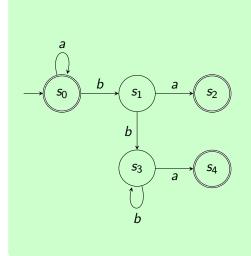


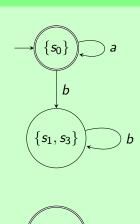


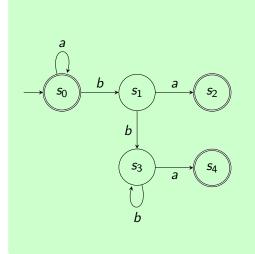
Exemple b $\{s_1,s_3\}$ **S**3

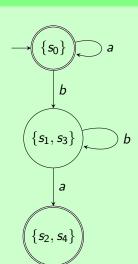








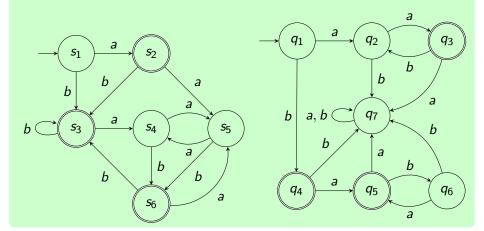




Minimisation d'un DFA: Exercice

Exercice

Minimisez les automates suivants :



Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

▶ lex est un constructeur d'analyseur lexical pour Unix;

- ▶ lex est un constructeur d'analyseur lexical pour Unix;
- Il génère un automate fini déterministe;

- lex est un constructeur d'analyseur lexical pour Unix;
- ▶ Il génère un automate fini déterministe ;
- ▶ Un outil ayant ses fonctionalités fait partie du standard POSIX ;

- lex est un constructeur d'analyseur lexical pour Unix;
- Il génère un automate fini déterministe;
- ▶ Un outil ayant ses fonctionalités fait partie du standard POSIX ;
- ► En pratique, on en utilise souvent une implémentation *open source* : flex.

- lex est un constructeur d'analyseur lexical pour Unix;
- Il génère un automate fini déterministe;
- Un outil ayant ses fonctionalités fait partie du standard POSIX;
- En pratique, on en utilise souvent une implémentation open source :
 flex.

Définitions

%%

Syntaxe du fichier de définition : Règles (Expressions régulières)

%%

Code C

Lex – Exemple : eval.l

Plan

Introduction

Langages

Automates Finis Déterministes

Automates Finis Non Déterministes

Lex

Les expressions rationelles fournissent un bon compromis entre :

- Les expressions rationelles fournissent un bon compromis entre :
 - puissance d'expression;

- Les expressions rationelles fournissent un bon compromis entre :
 - puissance d'expression;
 - et efficacité.

- Les expressions rationelles fournissent un bon compromis entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;

- Les expressions rationelles fournissent un bon compromis entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- ▶ Il existe des outils pour créer ces analyseurs lexicaux;

- Les expressions rationelles fournissent un bon compromis entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- Il existe des outils pour créer ces analyseurs lexicaux;
- Les automates finis sont également très utilisés pour modéliser ou analyser des systèmes à événements discrets :

- Les expressions rationelles fournissent un bon compromis entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- Il existe des outils pour créer ces analyseurs lexicaux;
- Les automates finis sont également très utilisés pour modéliser ou analyser des systèmes à événements discrets :
 - programmes;

- Les expressions rationelles fournissent un bon **compromis** entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- Il existe des outils pour créer ces analyseurs lexicaux;
- Les automates finis sont également très utilisés pour modéliser ou analyser des systèmes à événements discrets :
 - programmes;
 - systèmes biologiques;

- Les expressions rationelles fournissent un bon **compromis** entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- ▶ Il existe des outils pour créer ces analyseurs lexicaux ;
- Les automates finis sont également très utilisés pour modéliser ou analyser des systèmes à événements discrets :
 - programmes;
 - systèmes biologiques;
 - systèmes de production;

- Les expressions rationelles fournissent un bon **compromis** entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- Il existe des outils pour créer ces analyseurs lexicaux;
- Les automates finis sont également très utilisés pour modéliser ou analyser des systèmes à événements discrets :
 - programmes;
 - systèmes biologiques;
 - systèmes de production;
 - scénarios (de jeux);

- Les expressions rationelles fournissent un bon **compromis** entre :
 - puissance d'expression;
 - et efficacité.
- On peut en dériver automatiquement un DFA qui s'implémente facilement et efficacement;
- Il existe des outils pour créer ces analyseurs lexicaux;
- Les automates finis sont également très utilisés pour modéliser ou analyser des systèmes à événements discrets :
 - programmes;
 - systèmes biologiques;
 - systèmes de production;
 - scénarios (de jeux);
 - **.** . . .